

## 第 3 册 RAG知识库与历史工单经验

本册完整收录对应专题的原始内容，保留代码事实、现有限制与改进建议的区分。供开发维护和 AI 项目理解使用，不应直接发布为面向客户的售后政策。

本册专题：知识库检索与历史经验

### 知识库检索与历史经验

#### 两种知识库不能混在一起

本项目文档知识库用于理解代码、运维和开发；产品中的企业知识库用于向客户回答企业政策与产品问题。内部架构文档、故障恢复策略和安全限制不应默认作为面向客户的公开业务政策发布。产品中的发布动作意味着该企业客户的模型问答可以检索资料，不只是“保存文件”。

RAG 的含义是先检索外部资料，再让模型基于命中内容回答。它不把文档训练进 DeepSeek 权重，也不保证检索不到时模型知道企业实际政策。企业知识和聊天模型的上下文窗口是不同概念。

#### 文档从创建到发布

员工在 `/staff/knowledge` 录入标题与正文，或上传 UTF-8 TXT/Markdown。保存创建未发布的 KnowledgeDocument，不调用向量 API。文件名只取最后一个路径段，去掉目录含义，不将上传路径原样写到文件系统，不执行 Markdown 中的脚本或命令。

上传最多读取 240001 字节，用于判断是否超过 240000 字节限制。支持 UTF-8 BOM，拒绝空文本、零字节字符和解码失败；正文最多 60000 字符，标题最多 200 字符。240 KB 在代码中具体是 240000 字节，不应擅自理解成 240 KiB。

点击生成分块预览时，服务锁定文档并检查 `draft_revision`，读取保存的原文生成草稿。这个过程不调用 Embedding。生成会覆盖待发布草稿，因此已有分块时界面先确认；它不会立即替换线上索引。

草稿片段保存在文档 JSONB，正式片段保存在 `knowledge_chunks`。员工可以查看原文、正式片段和待发布草稿，修改章节路径、正文、拆分位置或合并同章节相邻片段。没有把自动分块认定成自动完成语义审核。

保存分块要求每个正文非空、最多 2000 字符，章节路径非空、最多 1500 字符，片段数 1 到 300，正文总长度最多 120000 字符。总长度限制防止手动复制形成无限重复。保存只增加草稿版本，不替换线上知识。

发布必须提交员工看见的版本号。服务持有文档行锁，校验版本和片段，生成全部新向量后才替换旧片段并提交。一旦向量失败，事务回滚，原线上片段仍然保留。整个发布外层 35 秒超时，小文档同步处理，不是后台任务队列。

若模型指纹相同且待发布的实际索引文本与现有完全一致，可以复用已有向量、更新发布版本，避免重复收费。这个复用分支不能推出“每次点击发布都一定调用向量服务”。

停用只把 `published` 设为 `false`，新检索不再使用；数据库原文和片段不删除，过去已经发出的聊天回复也不会被追溯撤回。已发布文档编辑草稿后，旧线上版本持续生效直到新版本发布成功。

## 结构化分块算法

`knowledge_chunking.build_draft` 先识别标题结构。支持 Markdown 一级到六级标题，常见中文“一、”“二、”标题会转换为二级标题；“退货”“换货”“维修”“安装与使用”“退货与维修”等明确短标题转换为三级。不会把每个短句、每条数字列表都猜成章节。

代码围栏内的内容保留，不拿其中看似标题的字符串改写文档层级。没有识别到标题时按段落兜底，并给员工警告；标题后直接接下级标题或文末，也提示检查是否是正常目录还是遗漏正文。

实际使用 `MarkdownHeaderTextSplitter` 提取章节及祖先标题。片段所属路径以文档标题开始，再追加各级标题。正文不超过 800 字符时，保留完整章节；超过 800 时才使用 `RecursiveCharacterTextSplitter`，以约 500 字符、60 字符重叠继续拆分，优先按空行、换行、句号、分号和空格找边界。

因此 500 是长章节切分目标，不是每个片段严格长度，更不是 Token 数。保留完整条件与例外比强行凑成等长片段重要。重叠只帮助长章节上下文衔接，不代表越多越好，也没有把不同产品章节跨界拼接为统一规则。

自动算法不能识别全部法律或业务依赖。例如正文里的“以上条件”可能依赖前段，长表格可能被拆开，多个相互矛盾的规则也不会自动裁决。警告必须人工查看。当前分块不是语义模型分块，没有用 LLM 重写原政策。

手动拆分按 Unicode 字符计数，避免拆断 emoji 的 UTF-16 码元。只有相邻片段且 `heading_path` 一致才允许合并；合并不会静默删掉重叠文字，员工需核对重复条件。保存后的分块与原始正文可以不同，当前没有同步重写原文的通用编辑接口。

`indexed_text` 将“所属章节：路径”和正文一起送去向量化，并在检索时提供同样上下文。数据库仍将章节路径和正文分开保存，便于界面检查。当前版本标记为 `structure-v1`。

## 向量服务与配置指纹

知识库必须独立配置 `enabled`、API key、base URL、model、dimensions。不会自动复用 DeepSeek 聊天密钥；聊天成功不代表 Embedding 接口可用。`OpenAIEmbeddings` 在这里表示兼容协议适配器。

客户端发送原始文本，禁用按 OpenAI Token ID 预切分，指定 float 编码，不假定供应商支持 `dimensions` 参数。SDK 超时 25 秒、自动重试 0、批量 `chunk_size` 为 16。这里 `chunk_size 16` 是一次嵌入请求的批量参数，不是业务文本切片长度。

返回向量必须与片段数量相符，每个维度必须等于配置，所有数值必须有限且向量不能全零。错误时索引不发布。修改 `dimensions` 只是修改预期检查值，不会神奇改变模型输出维数；必须按供应商实际模型输出配置。

`embedding_profile` 是去除末尾斜杠的接口地址、模型名和维度组合的 SHA-256。它用来防止不同模型空间混用，不是向量模型版本管理平台。地址、模型或维度变化后要重建索引；同名供应商模型若内部更新而配置字符串不变，目前不会自动发现，需要人工治理。

## 从问题到检索结果

意图节点判断问题涉及企业政策、产品说明、操作指南或历史案例时，填写 `should_search_knowledge` 与 `knowledge_query`。`query` 可结合历史指代形成独立问题，最长 500 字符；不是每条聊天都检索。

纯 RAG 分支由 `prepare_knowledge_node` 产生工具调用，再由 `search_company_knowledge` 验证 Runtime 会话企业与客户是否匹配。工具不允许模型指定别的企业。`Service` 在 SQL 中限制当前企业、已发布文档和相同模型指纹。

服务先验证配置，再确认是否有当前模型可用资料。没有资料时不发送无意义的向量请求。存在资料时对问题进行嵌入，外层 30 秒预算，再通过 `pgvector` 余弦距离排序。

数据库当前执行精确检索，按距离和片段 ID 排序取前五个，再用 `1 - distance` 与 `knowledge_min_score` 比较。默认阈值 0.5，配置范围 -1 到 1。相似度是检索信号，不是准确率或“50% 可信”。响应分数四舍五入到五位小数，而阈值比较使用原值。

SQL 使用 CASE 避免优化器提前对不兼容维度做距离计算。当前没有 HNSW/IVFFlat 近似索引、BM25 混合召回、重排器、自动查询分解和知识图谱扩展。数据量变大后性能和召回要专门评测，不能以小规模演示推断生产吞吐。

## 生成答案与引用

知识问答模型只拿本轮问题和检索片段，不携带写工具。提示词要求将文档、标题、问题视为数据，不执行其中指令；资料不相关、矛盾或不足时不能编造政策。

模型返回 `answer` 和 `source_numbers`。服务端检查引用非空且序号在实际命中范围内，再从数据库真实文档标题和片段位置形成简短引用；同一文档合并。数字 1 表示本轮命中序号，不一定是原文片段 1，展示引用时转换成真实 `position`。

默认回答力求礼貌、简短、一到三句；这主要是提示词约束，不是对自然语言绝对长度的运行时保证。服务不机械截断正文，以免截掉限制条件。界面以普通文本显示，Markdown 星号不自动意味着富文本渲染。

检索无结果、服务错误、模型未配置或引用无效有不同保守回复。纯知识回答中“建议联系人工”只是建议，不自动等于已经进入人工队列；实际排队取决于 `requires_human` 和会话服务持久化。订单售后预判分支有明确的人工排队处理，不应混淆。

合法引用只证明“引用了一个存在的片段”，不能证明回答中的每一句都被该片段支持。注入防护、事实一致性、政策冲突和真实模型效果仍需要评测和员工审核。

## 历史工单经验的来源与审核

“从工单整理经验”通过数据库分页查询当前企业已解决或已关闭工单，支持编号和标题关键词，每页二十条。找不到某条工单时先核对登录企业、当前状态、关键词和分页，而不是自动把其他企业工单开放。

选择后取回脱敏标题、问题描述、客户诉求、影响说明。这些是素材。服务不把客户诉求当作实际处理方法，也不假装数据库已有已核实原因字段。员工必须填写实际解决办法、原因和适用限制；原因不确定时可写未确认。

保存案例会锁来源工单，校验企业与完结状态，并检查一单一文档的唯一约束。正文明确标记为历史案例，分成现象、原因、办法、适用范围。source\_kind 为 ticket\_case，客户检索不返回原始来源工单 ID。

辅助脱敏会替换已知客户名称、用户名、邮箱、业务编号、客户 UUID，并对常见邮箱、手机号、身份证号、TK/MO 编号、UUID 做规则替换。先处理较长标识避免短标识破坏匹配。规则既可能漏掉开放地址与第三方姓名，也可能误替换普通文本，不能视为自动匿名化证明。

发布案例前必须提交显式审核确认与员工身份；检查标题、章节路径和每个待发布片段是否仍含可识别信息。来源工单若已重新变成处理中，会阻止再次发布。已经发布的案例在工单随后重开时，不会自动停用旧索引；需要知识管理者复核和停用，这属于当前限制。

案例回答要说明“以往类似案例”，不等同于统一政策，不保证同样结果或赔付金额。售后预判只使用正式 document 片段。如果前五个召回都被案例占据，正式政策可能未进入命中，预判会保守转人工；目前未做正式政策与案例独立召回配额。

## 员工误操作保护和边界

未保存编辑不能直接发布；修改后需要保存并重新审核案例。关闭分块详情抽屉前若有脏数据，会提示是否放弃。重新生成草稿有覆盖确认，版本不一致返回 409，避免把另一员工更新静默覆盖。

这些保护不等于浏览器异常退出自动保存。普通文档创建和上传也没有与聊天一样的持久化客户端请求幂等键，响应丢失后盲目重传可能生成重复文档，应先刷新列表核对。

企业所有当前授权员工共享知识管理范围，尚无作者/审核者职责分离、双人审批、定时生效、文档撤回通知和完整多版本归档。资料一旦发送给模型或显示给客户，停用不能收回已经离开数据库的信息。

主要源码为 services/knowledge\_service.py、knowledge\_chunking.py、ticket\_experience\_service.py、agent/workflows/knowledge\_workflow.py、api/knowledge\_routes.py、schema/knowledge.py、db/knowledge\_models.py 和前端 KnowledgeView、KnowledgeDraftEditor、TicketExperienceForm。